

# EM 算法用于混合高斯模型的参数估计

中国民航大学计算机学院，张志远

2010 年 2 月 25 日

## 1. 极大似然估计

假定随机变量  $X$  服从某一个参数为  $\theta$  的分布，其概率密度为  $P(x; \theta)$ ,  $\theta \in \Theta$ ，其中  $\theta$  为带估参数， $\Theta$  是  $\theta$  的可能取值范围。设  $X_1, X_2, \dots, X_n$  是来自  $X$  的样本，则  $X_1, X_2, \dots, X_n$  的联合分布概率为

$$\prod_{i=1}^n p(x_i; \theta)。$$

又设  $x_1, x_2, \dots, x_n$  是相应于样本  $X_1, X_2, \dots, X_n$  的一个样本值。则事件  $\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\}$  发生的概率为

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta), \theta \in \Theta$$

这一概率随  $\theta$  的取值变化而变化，称  $L(\theta)$  为样本的似然函数。

最大似然估计法就是根据固定样本观察值  $x_1, x_2, \dots, x_n$ ，在  $\theta$  可能的取值范围  $\Theta$  内挑选使似然函数  $L(\theta)$  达到最大的参数  $\hat{\theta}$ ，作为参数  $\theta$  的估计值。即取  $\hat{\theta}$  使

$$L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$$

称  $\log(L(\theta))$  为对数似然估计。

对于最大似然估计的求解一般通过微分学中的极值问题求解。 $\hat{\theta}$  一般可从方程

$$\frac{d}{d\theta} \ln(L(\theta)) = 0$$

求得。

## 2. EM 算法的一般描述

当有部分数据缺失或者无法观察到时，EM 算法提供了一个高效的迭代程序用来计算这些数据的最大似然估计。在每一步迭代分为两个步骤：期望（Expectation）步骤和最大化（Maximization）步骤，因此称为 EM 算法。

假设全部数据  $Z$  是由可观测到的样本  $X = \{X_1, X_2, \dots, X_n\}$  和不可观测到的样本  $Y = \{Y_1, Y_2, \dots, Y_n\}$  组成的，则  $Z = X \cup Y$ 。EM 算法通过搜寻使全部数据的似然

函数 $\text{Log}(L(Z; \theta))$ 的期望值最大来寻找极大似然估计 $\hat{\theta}$ ，注意此处的 $\theta$ 不是一个变量，而是多个变量组成的参数集合。此期望值是在 $Z$ 所遵循的概率分布上计算，此分布由未知参数 $\theta$ 确定。然而 $Z$ 所遵循的分布是未知的。EM算法使用其当前的假设 $\theta_{t-1}$ 代替实际参数 $\theta$ ，以估计 $Z$ 的分布。

$$Q(\theta, \theta_{t-1}) = E[\ln L(Z | \theta) | X, \theta_{t-1}]$$

EM算法重复以下两个步骤直至收敛。

步骤1：E步骤：使用当前假设 $\theta_{t-1}$ 和观测到的数据 $X$ 来估计 $Z$ 上的概率分布以计算 $Q(\theta, \theta_{t-1})$ 。

$$Q(\theta, \theta_{t-1}) \leftarrow E[\ln L(Z | \theta) | X, \theta_{t-1}]$$

步骤2：M步骤：求使函数 $Q(\theta, \theta_{t-1})$ 最大化的 $\theta$ 并将其作为下一次循环的假设 $\theta_t$ 。

$$\theta_t \leftarrow \arg \max_{\theta \in \Theta} Q(\theta, \theta_{t-1})$$

### 3. EM 算法用于 K 均值问题的参数估计

为简单起见，假设 $k=2$ ，然后再扩展到任意个 $k$ 的情况。

问题描述：假设 $X$ 是由2个高斯分布均匀混合而成的，这两个高斯分布的均值不同，但是具有相同的方差。设样本值为 $x_1, x_2, \dots, x_n$ ，其中每一个 $x_i$ 可以表示为一个三元组 $\langle x_i, z_{i1}, z_{i2} \rangle$ ，其中 $z_{i1}$ 和 $z_{i2}$ 中只能有一个取1，其余的为0。此处的 $z_{i1}$ 和 $z_{i2}$ 为隐藏变量，是未知的。此处的均匀混合是指 $x_i$ 可能来自于第一个分布，也可能来自于第二个分布，其概率相等。

步骤1：假定当前的假设 $h = \langle \mu_1, \mu_2 \rangle$ 成立，计算每个 $z_{ij}$ 的期望值，即实例 $x_i$ 由第 $j$ 个正态分布生成的概率的期望。

$$E[z_{ij}] = \frac{p(X = x_i | \mu = \mu_j)}{p(X = x_i)} = \frac{\text{Exp}(-\frac{1}{2\sigma^2}(x_i - \mu_j)^2)}{\sum_{k=1}^2 \text{Exp}(-\frac{1}{2\sigma^2}(x_i - \mu_k)^2)}$$

步骤2：使用第一步中计算出来的 $E[z_{ij}]$ 来导出新的极大似然假设 $h' = \langle \mu_1', \mu_2' \rangle$ 。

$$\mu_j \leftarrow \frac{\sum_{i=1}^n E[z_{ij}] x_i}{\sum_{i=1}^n E[z_{ij}]}$$

#### 3.1 对于任意个 K 的扩展

问题描述：假设X是由K个高斯分布均匀混合而成的，这K个高斯分布的均值不同，但是具有相同的方差。设样本值为 $x_1, x_2, \dots, x_n$ ，其中每一个 $x_i$ 可以表示为一个K+1 元组 $\langle x_i, z_{i1}, z_{i2}, \dots, z_{ik} \rangle$ ，其中只有一个取 1，其余的为 0。此处的 $z_{i1}$ 到 $z_{ik}$ 为隐藏变量，是未知的。且任意 $z_{ij}$ 被选择的概率相等，即

$$P\{z_{ij} = 1, j = 1, 2, \dots, K\} = \frac{1}{K}。$$

步骤 1：求 $E[\ln P(Y|h')]$ 。注意每个实例 $y_i = \langle x_i, z_{i1}, z_{i2}, \dots, z_{ik} \rangle$ 的概率 $p(y_i | h')$ 为：

$$p(y_i | h') = p(x_i, z_{i1}, \dots, z_{ik} | h') = \frac{1}{\sqrt{2\pi\sigma^2}} \text{Exp}\left(-\frac{1}{2\sigma^2} \sum_{j=1}^k z_{ij} (x_i - u'_j)^2\right)$$

注意只有一个 $z_{ij}$ 值为 1，其余的为 0。因此：

$$\ln P(Y | h') = \ln \prod_{i=1}^n p(y_i | h') = \sum_{i=1}^n \ln p(y_i | h') = \sum_{i=1}^n \left( \ln \frac{1}{\sqrt{2\pi\sigma^2}} - \frac{1}{2\sigma^2} \sum_{j=1}^k z_{ij} (x_i - u'_j)^2 \right)$$

因此有：

$$\begin{aligned} E[\ln P(Y | h')] &= E \left[ \sum_{i=1}^n \left( \ln \frac{1}{\sqrt{2\pi\sigma^2}} - \frac{1}{2\sigma^2} \sum_{j=1}^k z_{ij} (x_i - u'_j)^2 \right) \right] \\ &= \sum_{i=1}^n \left( \ln \frac{1}{\sqrt{2\pi\sigma^2}} - \frac{1}{2\sigma^2} \sum_{j=1}^k E[z_{ij}] (x_i - u'_j)^2 \right) \end{aligned}$$

而：

$$E[z_{ij}] = \frac{p(X = x_i | \mu = \mu_j)}{p(X = x_i)} = \frac{\text{Exp}\left(-\frac{1}{2\sigma^2} (x_i - \mu_j)^2\right)}{\sum_{k=1}^K \text{Exp}\left(-\frac{1}{2\sigma^2} (x_i - \mu_k)^2\right)}$$

步骤 2：求使 $E[\ln P(Y|h')]$ 期望最大的假设 $h' = \langle \mu'_1, \dots, \mu'_k \rangle$

对 $E[\ln P(Y|h')]$ 求 $\mu'_j$ 的偏导数：

$$\frac{\partial}{\partial \mu'_j} E[\ln P(Y | h')] = \sum_{i=1}^n \frac{1}{\sigma^2} E[z_{ij}] (\mu'_j - x_i) = \sum_{i=1}^n \frac{1}{\sigma^2} E[z_{ij}] \mu'_j - \sum_{i=1}^n \frac{1}{\sigma^2} E[z_{ij}] x_i = 0$$

因此，得：

$$\mu'_j = \frac{\sum_{i=1}^n E[z_{ij}] x_i}{\sum_{i=1}^n E[z_{ij}]}$$

## 3.2 Matlab 实现




图 1 测试样本的分布情况

```
% EM 测试用于模拟 2 个正态分布的均值估计
% 中国民航大学计算机学院，张志远
% 2010 年 2 月 25 日

% -----
% 生成符合条件的随机样本
% -----
% 首先指定两个高斯分布的参数，注意这两个高斯分布的方差相同
Sigma = 6;
Miu1 = 40;
Miu2 = 20;
% 然后随机均匀选择两种高斯分布，并生成样本值
N = 1000;
X = zeros(1, N);
for i=1:N
    if rand > 0.5 % 选择第一个高斯分布
        X(1,i) = randn * Sigma + Miu1;
    else % 选择第二个高斯分布
        X(1,i) = randn * Sigma + Miu2;
    end
end

% -----
% EM 算法，步骤 1，计算 E[Zij]
% -----
% 首先假设两个高斯分布的均值为随机的两个值
k = 2;
Miu = rand(1,k);
Expectations = zeros(N, k);

for step = 1 : 1000
    % 计算 E[Zij]
```

```

for i = 1 : N
    % 计算分母
    Denominator = 0;
    for j = 1 : k
        Denominator = Denominator + exp(-1/(2*Sigma^2) * (X(1,i)-Miu(1,j))^2);
    end
    for j = 1 : k
        % 计算分子
        Numerator = exp(-1/(2*Sigma^2) * (X(1,i)-Miu(1,j))^2);
        Expectations(i,j) = Numerator / Denominator;
    end
end

% -----
% EM 算法，步骤 2，求最大化 E[Zij]的参数 Miu
% -----
OldMiu = Miu;
for j = 1 : k
    Numerator = 0;
    Denominator = 0;
    for i = 1 : N
        Numerator = Numerator + Expectations(i,j) * X(1,i);
        Denominator = Denominator + Expectations(i,j);
    end
    Miu(1,j) = Numerator / Denominator;
end

% -----
% 判断假设是否发生了足够的变化
% -----
Epsilon = 0.0001;
if sum(abs(Miu - OldMiu)) < Epsilon
    break;
end
step
Miu
end
disp('=====Miu=====');
Miu
hist(X,50)

```

输出结果：

在第 13 步时迭代终止，得均值估计为：

Miu = [19.9747    40.2692]

讨论，如果初始值设置的两个 Miu 值相同，例如 Miu=[0, 0]，则迭代一次即终止，始终得不到正确的结果。

#### 4. EM 算法用于混合高斯模型

混合模型是指随机变量 X 的概率密度为：

$$p(x|\Theta) = \sum_{k=1}^M \alpha_k p_k(x|\theta_k), \text{ 且 } \sum_k \alpha_k = 1$$

此处的  $\Theta=(\alpha_1, \dots, \alpha_M, \theta_1, \dots, \theta_M)$ ，即混合模型由 M 个分量组成，每个分量的权重系数为  $\alpha_k$ 。如果每一个分量都满足高斯分布，则称其为混合高斯模型。由此可知，上面的 K 均值问题是混合高斯分布的一个特例。

例如一个班级学生的身高为 X，假设男生和女生的身高分别服从  $N(\mu_1, \sigma_1^2)$  和  $N(\mu_2, \sigma_2^2)$ ，则  $X \sim \alpha_1 N(\mu_1, \sigma_1^2) + \alpha_2 N(\mu_2, \sigma_2^2)$ ，且  $\alpha_1 + \alpha_2 = 1$ ， $0 \leq \alpha_1, \alpha_2 \leq 1$ 。

对数似然函数：

$$\ln(L(\Theta|X)) = \ln \prod_{i=1}^N p(x_i|\Theta) = \sum_{i=1}^N \ln \left( \sum_{k=1}^M \alpha_k p_k(x_i|\theta_k) \right)$$

这个函数因为含有加法的对数，不太好直接计算极值，因此将其改写为含有引变量 Y 的函数。设  $Y=(y_1, y_2, \dots, y_N)$ ，且  $y_i \in \{1, 2, \dots, M\}$ ， $i=1, 2, \dots, N$ 。当  $y_i=k$  时表示第 i 个样本观测值  $x_i$  是由第 k 个分量产生的。因此，引入隐含变量 Y 后的对数似然函数为：

$$\ln(L(\Theta|X, Y)) = \ln \prod_{i=1}^N p(x_i, y_i|\Theta) = \sum_{i=1}^N \ln(\alpha_{y_i} p_{y_i}(x_i|\theta_{y_i}))$$

**步骤 1：**求完整数据的对数似然函数的期望。注意变量是 Y，且 X 和  $\Theta^{t-1}$  已知。此处的  $Y=(y_1, \dots, y_N)$ ， $\Theta^{t-1}=(\alpha_1^{t-1}, \dots, \alpha_M^{t-1}, \theta_1^{t-1}, \dots, \theta_M^{t-1})$  是上次推出的假设参数值（初始参数可以随机指定）。

$$\begin{aligned} Q(\Theta, \Theta^{t-1}) &= E[\ln(L(\Theta|X, Y))] = \sum_y \ln(L(\Theta|X, y)) p(y|X, \Theta^{t-1}) \\ &= \sum_y \sum_{i=1}^N \ln(\alpha_{y_i} p_{y_i}(x_i|\theta_{y_i})) p(y|x_i, \Theta^{t-1}) \end{aligned}$$

第 i 个观测样本  $x_i$  取第 k 个分量的概率密度为  $p(y_i=k|x_i, \Theta^{t-1})$ 。因此上式

$$\begin{aligned}
&= \sum_{k=1}^M \sum_{i=1}^N \text{Ln}(\alpha_k p_k(x_i | \theta_k)) p(k | x_i, \Theta^{t-1}) \\
&= \sum_{k=1}^M \sum_{i=1}^N \text{Ln}(\alpha_k) p(k | x_i, \Theta^{t-1}) + \sum_{k=1}^M \sum_{i=1}^N \text{Ln}(p_k(x_i | \theta_k)) p(k | x_i, \Theta^{t-1})
\end{aligned}$$

由于每一个成分都满足高斯分布，因此

$$p_k(x_i | \theta_k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \text{Exp}\left(-\frac{(x_i - \mu_k)^2}{2\sigma_k^2}\right)$$

而由贝叶斯公式，可得：

$$p(k | x_i, \Theta^{t-1}) = \frac{p(k, x_i | \theta_k^{t-1})}{\sum_{k'=1}^M p(k', x_i | \theta_{k'}^{t-1})} = \frac{p_k(x_i | \theta_k^{t-1})}{\sum_{k'=1}^M p_{k'}(x_i | \theta_{k'}^{t-1})}$$

**步骤二：**求满足期望最大的参数 $\Theta^t$ 。

**【1】**求 $\mu_k$

对 $\mu_k$ 求偏导数得：

$$\begin{aligned}
\frac{\partial}{\partial \mu_k} Q(\Theta, \Theta^{t-1}) &= \frac{\partial}{\partial \mu_k} \left( \sum_{i=1}^N \text{Ln}(p_k(x_i | \theta_k)) p(k | x_i, \Theta^{t-1}) \right) \\
&= \frac{\partial}{\partial \mu_k} \left( \sum_{i=1}^N \left( \text{Ln} \frac{1}{\sqrt{2\pi\sigma_k^2}} - \frac{(x_i - \mu_k)^2}{2\sigma_k^2} \right) p(k | x_i, \Theta^{t-1}) \right) \\
&= \sum_{i=1}^N \left( \frac{1}{\sigma_k^2} (x_i - \mu_k) p(k | x_i, \Theta^{t-1}) \right) \\
&= \frac{1}{\sigma_k^2} \sum_{i=1}^N (x_i p(k | x_i, \Theta^{t-1}) - \mu_k p(k | x_i, \Theta^{t-1})) \\
&= \frac{1}{\sigma_k^2} \sum_{i=1}^N (x_i p(k | x_i, \Theta^{t-1})) - \frac{\mu_k}{\sigma_k^2} \sum_{i=1}^N p(k | x_i, \Theta^{t-1}) \\
&= 0
\end{aligned}$$

由此，我们得到：

$$\mu_k = \frac{\sum_{i=1}^N x_i p(k | x_i, \Theta^{t-1})}{\sum_{i=1}^N p(k | x_i, \Theta^{t-1})}$$

**【2】**求 $\sigma_k^2$

对 $\sigma_k^2$ 求偏导数得：

$$\begin{aligned}
\frac{\partial}{\partial \sigma_k^2} \mathcal{Q}(\Theta, \Theta^{t-1}) &= \frac{\partial}{\partial \sigma_k^2} \left( \sum_{i=1}^N \text{Ln}(p_k(x_i | \theta_k)) p(k | x_i, \Theta^{t-1}) \right) \\
&= \frac{\partial}{\partial \sigma_k^2} \left( \sum_{i=1}^N \left( \text{Ln} \frac{1}{\sqrt{2\pi\sigma_k^2}} - \frac{(x_i - \mu_k)^2}{2\sigma_k^2} \right) p(k | x_i, \Theta^{t-1}) \right) \\
&= \frac{\partial}{\partial \sigma_k^2} \left( \sum_{i=1}^N \left( -\frac{1}{2} \text{Ln}(2\pi) - \frac{1}{2} \text{Ln}(\sigma_k^2) - \frac{(x_i - \mu_k)^2}{2\sigma_k^2} \right) p(k | x_i, \Theta^{t-1}) \right) \\
&= \sum_{i=1}^N \left( -\frac{1}{2\sigma_k^2} + \frac{(x_i - \mu_k)^2}{2(\sigma_k^2)^2} \right) p(k | x_i, \Theta^{t-1}) \\
&= \frac{1}{2(\sigma_k^2)^2} \sum_{i=1}^N \left( (x_i - \mu_k)^2 - \sigma_k^2 \right) p(k | x_i, \Theta^{t-1}) \\
&= \frac{1}{2(\sigma_k^2)^2} \sum_{i=1}^N (x_i - \mu_k)^2 p(k | x_i, \Theta^{t-1}) - \frac{1}{2(\sigma_k^2)^2} \sum_{i=1}^N \sigma_k^2 p(k | x_i, \Theta^{t-1}) \\
&= 0
\end{aligned}$$

由此，我们得到：

$$\sigma_k^2 = \frac{\sum_{i=1}^N (x_i - \mu_k)^2 p(k | x_i, \Theta^{t-1})}{\sum_{i=1}^N p(k | x_i, \Theta^{t-1})}$$

### 【3】求 $\alpha_k$

求 $\alpha_k$ 需要借助于拉格朗日乘子，不能单纯使用偏导数求解，因为所有的 $\alpha_k$ 加起来必须等于1。

$$\begin{aligned}
\frac{\partial}{\partial \alpha_k} \left[ \mathcal{Q}(\Theta, \Theta^{t-1}) + \lambda \left( \sum_{k=1}^M \alpha_k - 1 \right) \right] &= 0 \\
\frac{\partial}{\partial \alpha_k} \left[ \sum_{k=1}^M \sum_{i=1}^N \text{Ln}(\alpha_k) p(k | x_i, \Theta^{t-1}) + \lambda \left( \sum_{k=1}^M \alpha_k - 1 \right) \right] &= 0 \\
\frac{1}{\alpha_k} \sum_{i=1}^N p(k | x_i, \Theta^{t-1}) + \lambda &= 0 \\
\sum_{i=1}^N p(k | x_i, \Theta^{t-1}) + \lambda \alpha_k &= 0
\end{aligned}$$

将所有的M个 $\alpha_k$ 式子加起来，得：

$$\begin{aligned}
\sum_{k=1}^M \left[ \sum_{i=1}^N p(k | x_i, \Theta^{t-1}) + \lambda \alpha_k \right] &= 0 \\
\sum_{i=1}^N \sum_{k=1}^M p(k | x_i, \Theta^{t-1}) + \lambda \sum_{k=1}^M \alpha_k &= 0
\end{aligned}$$



注意到:  $\sum_{k=1}^M p(k | x_i, \Theta^{t-1}) = 1, \sum_{k=1}^M \alpha_k = 1$ 。

因此有:  $\lambda = -N$ , 得

$$\alpha_k = -\frac{1}{N} \sum_{i=1}^N p(k | x_i, \Theta^{t-1})$$

#### 4.1 Matlab 实现




图 2 测试样本的分布情况

```
% EM 测试用于模拟 k 个正态分布的混合模型的参数估计
% 中国民航大学计算机学院，张志远
% 2010 年 2 月 27 日

% -----
% 生成符合条件的随机样本
% -----
% 首先指定两个高斯分布的参数
Miu1 = 3;
Miu2 = -2;
Sigma1 = 1;
Sigma2 = 2;
Alpha1 = 0.4;
Alpha2 = 0.6;
% 然后 alpha1 和 alpha2 的概率选择两种高斯分布，并生成样本值
N = 5000;
X = zeros(1, N);
N1 = floor(N * Alpha1);           %第一种分布的样本数
N2 = N - N1;                     %第二种分布的样本数
X(1:N1) = randn(1, N1) * Sigma1 + Miu1;
X(N1+1:N) = randn(1, N2) * Sigma2 + Miu2;
hist(X,50)
% -----
% EM 算法，步骤 1，计算均值
```

```

% -----
% 首先假设两个高斯分布的均值为随机的两个值,注意此处的 Sigma 是 Sigma 的平方。
M = 2;
Miu = rand(1,M);
Sigma = rand(1,M);
Alpha = [0.2, 0.8];

PkMatrix = zeros(N, M);

for step = 1 : 100
    % 计算均值
    for i = 1 : N
        for k = 1 : M
            PkMatrix(i,k) = exp(-1*(X(1,i)-Miu(1,k))^2/(2*Sigma(1,k))) / sqrt(2*pi*Sigma(1,k));
        end
    end
    % SumPkMatrixI 是 N*1 的矩阵, 其每一行的值等于 P1i + P2i + P3i + ... + PMi
    % 即 SumPkMatrixI 是对 PkMatrix 按行相加的结果
    SumPkMatrixI = sum(PkMatrix, 2);
    for i = 1 : N
        PkMatrix(i,:) = PkMatrix(i,:) / SumPkMatrixI(i,1);
    end

    % -----
    % EM 算法, 步骤 2, 求最大化的参数 Miu,Sigma 和 Alpha
    % -----
    OldMiu = Miu;
    OldSigma = Sigma;
    OldAlpha = Alpha;
    for k = 1 : M
        P1 = 0;
        P2 = 0;
        for i = 1 : N
            P1 = P1 + PkMatrix(i,k);
            P2 = P2 + PkMatrix(i,k) * X(1,i);
        end
        Miu(1,k) = P2/P1;
        Alpha(1,k) = P1 / N;

        % 注意必须先计算好 Miu 才能计算 P3,
        % 因为要计算 Sigma 用到的 P3 依赖于的是新的 Miu
        P3 = 0;
        for i = 1 : N
            P3 = P3 + PkMatrix(i,k) * (X(1,i)-Miu(1,k))^2;
        end
    end
end

```

```

        end
        Sigma(1,k) = P3/P1;
    end

    % -----
    % 判断假设是否发生了足够的变化
    % -----
    Epsilon = 0.0001;
    if sum(abs(Miu - OldMiu)) < Epsilon &&
        sum(abs(Sigma - OldSigma)) < Epsilon &&
        sum(abs(Alpha - OldAlpha)) < Epsilon
        break;
    end
    disp('=====');
    step
    Miu
    Sigma
    Alpha
end

```

输出结果：

在第 33 步时迭代终止，得参数估计值为（注意此处的Sigma是指 $\sigma^2$ ）：

Miu = [2.8246    -2.2027]

Sigma = [1.2007    3.2662]

Alpha = [0.4421    0.5579]

讨论，如果初始值设置的 Alpha 不满足和等于 1 的条件，也不影响最后的结果。

## 参考文献

- 【1】盛骤等，概率论与数理统计[M]，浙江大学出版社，高等教育出版社
- 【2】Tom M. Mitchell著，曾华军等译，机器学习，机械工业出版社
- 【3】A. P. DEMPSTER, N. M. LAIRD and D. B. RDIN, Maximum Likelihood from Incomplete Data via the EM Algorithm
- 【4】J. A. Bilmes (1998), A General Tutorial of the EM Algorithm and its Application to Parameter Estimation for Gaussian Mixture and Hidden Markov Models.
- 【5】Jiangsheng Yu, Expectation Maximization-An Approach to Parameter Estimation, <http://icl.pku.edu.cn/yujs/papers/pdf/EM.pdf>
- 【6】李昌利，沈玉利，期望最大算法及其应用(2)，计算机工程与应用，2008年第44卷30期