

引入 GMM 的目的和两大作用

参数估计方法主要有最小二乘法，极大似然估计法，矩估计法。

GMM 的引入有一定的意义。

首先，处理大样本数据时，如果不知道变量的分布，GMM 估计方法优于 MLE。

极大似然估计法¹和广义矩估计法²被用于大样本情况下模型参数的估计，它们在大样本条件下显示了优良的性质。但是，使用极大似然估计法的前提是已知变量的分布，只是不知道其参数。此时，分布的设定难免有人为的因素，一旦给出了错误的分布假定，MLE 估计量通常是**有偏的**。而广义矩估计方法不需要对变量的分布进行假定，它只需要找到一些矩条件而不是整个密度函数；基于模型实际参数满足一定的矩条件，GMM 估计量总是**一致的**。当然，GMM 有时不能对样本中的全部信息进行有效利用。此外，只有当样本很大时，GMM 估计量才是**渐近有效的**。而在小样本中尽管也是一致的，但却不是有效的。其拥有十分良好的大样本性质，它的小样本性质并不令人满意。

GMM 与 MLE 的差别还在于，在某些情况下，GMM 的计算较 MLE 方便。

其次，GMM 是对工具变量法的补充和完善。当解释变量存在内生性时，研究者是通过寻找工具变量来解决此问题。当工具变量满足的矩条件个数大于待估计参数个数时，方程组的解不唯一。此时，运用广义矩估计法，即使不能够从一阶条件得出解，但它仍能对未知参数进行估计，并且得到渐进有效的参数估计值。

第三，GMM 估计方法允许模型设定中存在异方差和相关性。GMM 方法中权矩阵的选取，考虑了随机误差项的异方差和自相关。即针对异方差或者自相关，GMM 估计方法有不同的权矩阵构造方法。

再次，假设检验。GMM 模型中，设计了多个统计量对模型设定及其参数进行假设检验。

传统的计量经济学估计方法，例如普通最小二乘法、工具变量法和极大似然法等都存在自身的局限性。即其参数估计量必须在满足某些假设时，比如模型的随机误差项服从正态分布或某一已知分布时，才是可靠的估计量。解释变量外生时，估计的参数才是无偏的。而 GMM 不需要知道随机误差项的准确分布信息，允许随机误差项存在异方差和序列相关，因而所得到的参数估计量比其他参数估计方法更有效。

作用：

解决内生变量问题：

解决随机误差项存在异方差和序列相关问题：

参数，一致、渐进正态性

J 统计量，渐进卡方性，可以检验模型及其参数。

变量分布未知问题

¹极大似然估计法(maximum likelihood method, ML)的应用虽然没有普通最小二乘法广泛，但它是一个具有更强理论性质的点估计方法，它以极大似然原理为基础，通过概率密度函数或者分布律来估计总体参数。对于一些特殊类型的计量经济模型，如我们后面将介绍的 Logit 和 Probit 模型，最小二乘法不再适用，极大似然法成为首选的估计方法。极大似然法的思路 极大似然估计法的出发点是已知被观测现象的分布，但不知道其参数。极大似然法用得到观测值(样本)最高概率的那些参数的值来估计该分布的参数，从而提供了一种用于估计刻画一个分布的一组参数的方法。

²广义矩方法确实是一种具有高度概括性的方法。其他的参数估计量可以看做它的特例。比如最小二乘法估计量(OLS)和最大似然估计量(MLE)都是 GMM 估计量的特例。当待估参数较多时。最大似然估计需要较为复杂的数值求解。GMM 估计更加方便。GMM 在时间序列及面板数据分析等许多场合有着广泛的应用

GMM 用于线性模型和非线性模型的区别： $\hat{\beta} = \arg \min (g(\beta)'W^{-1}g(\beta))$

J 统计量的表达式中 g 在线性模型中能够用样本信息表达出来，而在非线性模型中，只能表达成隐函数。

在 GMM 统计量、参数估计方法、假设检验上，GMM 在线性模型和非线性模型中运用相同。

$$g(\beta) = \begin{pmatrix} g_1(\beta) \\ g_2(\beta) \\ \vdots \\ g_J(\beta) \end{pmatrix} = \begin{pmatrix} \frac{1}{n} \sum_i z_{1i} e_i \\ \frac{1}{n} \sum_i z_{2i} e_i \\ \vdots \\ \frac{1}{n} \sum_i z_{Ji} e_i \end{pmatrix}$$

2STS

vs

GMM

$y_i = X_i' \beta + \mu_i \quad i=1, \dots, n$

$X = Z \pi + \mu$

$\hat{\pi} = (Z'Z)^{-1} Z'X$

$\hat{X} = Z \hat{\pi} = Z(Z'Z)^{-1} Z'X$

$\hat{\beta} = (\hat{X}'X)^{-1} \hat{X}'Y = (X'Z(Z'Z)^{-1} Z'X)^{-1} (X'Z)(Z'Z)^{-1} Z'Y$

第1阶段估计

$\hat{\beta} = \text{Arg} \min \left\{ \frac{1}{n} [Z'(Y - X\beta)]' \cdot \hat{W}^{-1} \cdot \frac{1}{n} [Z'(Y - X\beta)] \right\}$

一阶导

$(X'Z)\hat{W}^{-1}(Z'Y - Z'X\hat{\beta}) = 0$

$(X'Z)\hat{W}^{-1}Z'Y - (X'Z)\hat{W}^{-1}Z'X\hat{\beta} = 0$

$(X'Z\hat{W}^{-1}Z'X)^{-1}(X'Z)\hat{W}^{-1}Z'Y = \hat{\beta}$

$\hat{W} = \frac{\hat{\sigma}^2}{n^2} Z'Z$

第2阶段估计

$\hat{\beta} = (X'Z(Z'Z)^{-1}Z'X)^{-1}(X'Z)(Z'Z)^{-1}Z'Y$

GMM 与 OLS、MLE、IV、GEE 的联系和区别

- 1, OLS: 选择解释变量作为工具变量构造矩条件，权利矩阵为单位阵，GMM 即为 OLS。参数估计值相同，参数估计量的方差—协方差矩阵一般不相同。
- 2, MLE: 用对数似然函数的导数构造等于 0 的矩条件时，所表示的 GMM 等价于 ML。
- 3, IV: GMM 中方程个数等于参数个数时，即等价于工具变量估计法。
- 4, 2STS: 2SLS 是工具变量估计方法的特殊情形，而工具变量估计是 GMM 估计的特殊情形。如果 GMM 中利用了所有先决变量，2SLS 与 GMM 估计等价。如上图。
- 5, 与 GEE 的对比，GMM 的使用场合是估计方程的个数大于未知参数的个数。而这两者相等时，可以使用 GEE。

GMM 的检验

对于 GMM，关键是两项检验：

一是检验过度识别限制是否有效。 $H_0: E(Z'U)=0$ 即 $J > k$ 的那部分是否有效。如果经过检验无效，那么 GMM 在这个意义上就没有优越性。如果拒绝原假设，意味着并非所有的总体矩条件都成立。如果拒绝原假设，而且没有进一步的信息，就不能判断哪个矩条件不成立，或者说哪个工具变量无效。

当 $l=k$ 时，称模型参数“恰好识别”，这时不论总体矩条件是否真的成立，都存在唯一解，意味着当 $l=k$ 时，总体矩条件不可检验。

当 $l > k$ 时，称模型参数“过度识别”，该检验称为过度识别约束检验。

过度识别约束检验也称为 Sargan 检验。

即，软件给出的结果是 J，但是判断时，要使用 nJ 。例如，某个模型计算得到 $J=0.029837$ ，那么， $nJ=0.477$ ，5%的显著性水平下，自由度为 1 的卡方分布的临界值为 3.84。接受过度识别的矩条件为真的假设。

在应用软件中，被称为 J 统计量，但应该是 $nJ \sim \chi^2(l-k)$

二是检验构造的矩条件是否成立。如果矩条件不成立，就要从模型设定方面寻找原因。

另外，如果对模型参数施加约束，则需要参数约束检验。

大数定律及中心极限定理 (依概率收敛)

切比雪夫大数定律, 伯努利大数定律, 辛钦定理

设随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立, 且具有相同的数学期望和方差: $E(X_k) = \mu, D(X_k) = \sigma^2 (k = 1, 2, \dots)$. 作前 n 个随机变量的算术平均

$$\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k$$

则对于任意正数 ϵ , 有

$$\lim_{n \rightarrow \infty} P\{|\bar{X} - \mu| < \epsilon\} = \lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n} \sum_{k=1}^n X_k - \mu\right| < \epsilon\right\} = 1.$$

这样, 上述定理又可叙述为:

定理一 设随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立, 且具有相同的数学期望和方差:

$E(X_k) = \mu, D(X_k) = \sigma^2 (k = 1, 2, \dots)$, 则序列 $\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k$ 依概率收敛于 μ , 即 $\bar{X} \xrightarrow{P} \mu$.

定理二 (伯努利大数定律) 设 n_A 是 n 次独立重复试验中事件 A 发生的次数. p 是事件 A 在每次试验中发生的概率, 则对于任意正数 $\epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{n_A}{n} - p\right| < \epsilon\right\} = 1$$

或

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{n_A}{n} - p\right| \geq \epsilon\right\} = 0.$$

定理三 (辛钦定理) 设随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立, 服从同一分布, 且具有数学期望 $E(X_k) = \mu (k = 1, 2, \dots)$, 则对于任意正数 ϵ , 有

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n} \sum_{k=1}^n X_k - \mu\right| < \epsilon\right\} = 1.$$

独立同分布中心极限定理, Liapunov 定理, 拉普拉斯极限定理

2. 中心极限定理

(1) 独立同分布的中心极限定理

(林德伯格—列维(Lindeberg—Levy)定理): 设随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立, 服从同一分布, 且具有相同的数学期望和方差: $E(X_k) = \mu, D(X_k) = \sigma^2 (k = 1, 2, \dots)$. 则随机变量

$$Y_n = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma}$$

的分布函数 $F_n(x)$ 收敛到标准正态分布. 即对任意 x 满足

$$\lim_{n \rightarrow +\infty} F_n(x) = \lim_{n \rightarrow +\infty} P\left\{\frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \leq x\right\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = \Phi(x).$$

独立同分布

独立同分布

意义:均值为 μ , 方差为 $\sigma^2 > 0$ 的独立同分布的随机变量 X_1, X_2, \dots, X_n 的和 $\sum_{k=1}^n X_k$ 的标准化变量, 当 n 充分大时, 有

$$Y_n = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \sim N(0, 1)$$

(2) 李雅普诺夫(liapunov) 定理

设随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立, $E(X_k) = \mu_k, D(X_k) = \sigma_k^2 (k = 1, 2, \dots)$ 存

在. 记 $B_n^2 = \sum_{k=1}^n \sigma_k^2$. 若存在正数 δ , 使得当 $n \rightarrow +\infty$ 时,

$$\frac{1}{B_n^{2+\delta}} \sum_{k=1}^n E\{|X_k - \mu_k|^{2+\delta}\} \rightarrow 0$$

则随机变量之和 $\sum_{k=1}^n X_k$ 的标准化变量

$$Z_n = \frac{\sum_{k=1}^n X_k - E\left(\sum_{k=1}^n X_k\right)}{\sqrt{D\left(\sum_{k=1}^n X_k\right)}} = \frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{\sqrt{B_n}}$$

的分布函数 $F_n(x)$ 对任意 x 满足

$$\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} P\left\{\frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{B_n} \leq x\right\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x)$$

(3) 德莫弗—拉普拉斯(De Moivre—Laplace) 定理

设随机变量 $\eta_n (n = 1, 2, \dots)$ 服从参数为 $n, p (0 < p < 1)$ 的二项分布, 则对于任意 x 有

$$\lim_{n \rightarrow \infty} P\left\{\frac{\eta_n - np}{\sqrt{np(1-p)}} \leq x\right\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x)$$

显然 $\eta_n = \sum_{k=1}^n X_k$, 其中 X_1, X_2, \dots, X_n 独立同服从 $B(1, p)$ 分布.

二 经典矩方法

1. 经典矩方法的步骤

用样本矩去代替总体矩，得到参数的估计，这种方法称为矩方法 (MOM)，也称为经典矩方法。

假设有一组随机样本 x_1, x_2, \dots, x_n ，服从 $k \times 1$ 维参数向量为 θ 的一种分布。用经典矩方法来估计 θ 的步骤如下：

首先，分别计算样本数据的 j 阶总体矩， $j=1, 2, \dots, k$ ，它们是 θ 的函数：

$$E(x_i^j) = \mu_j(\theta), j = 1, 2, \dots, k \quad (2.1)$$

其中 x_i^j 是 x_i 的 j 次方，它们可以不必是前 k 阶总体矩，但它们的形式一定要简单。包含参数 θ 的总体矩函数就是我们要求解的经济模型。

其次，根据大数定律 (LLN)，各阶样本矩依概率收敛于各阶总体矩，即：

$$\frac{1}{n} \sum_{i=1}^n x_i^j \xrightarrow{p} E(x_i^j), j = 1, 2, \dots, k \quad (2.2)$$

最后，用样本矩代替总体矩，解 k 个矩方程构成的方程组，解出来的 $\hat{\theta}_{MM}$ 就是 θ 的矩法估计量：

$$\frac{1}{n} \sum_{i=1}^n x_i^j = \mu_j(\hat{\theta}_{MM}), j = 1, 2, \dots, k \Rightarrow \hat{\theta}_{MM} \quad (2.3)$$

！ 向量值函数的经典矩方法

假定根据理论，有 k 个基于样本数据的函数，它们是一组未知参数 θ 的函数。向量值函数的经典矩估计可按照以下步骤进行：

首先，构造向量值函数 $g(x_i, \theta)$ ，它们是随机样本 x_i 和 $k \times 1$ 维参数向量 θ 的函数， $g(x_i, \theta)$ 可以是隐函数，使其 j 阶总体矩为零 ($j=1, 2, \dots, k$)：

$$E[g_j(x_i, \theta)] = 0, j = 1, 2, \dots, k \quad (2.4)$$

包含参数 θ 的零总体矩函数就是我们要求解的经济模型。

其次，向量值函数 $g_j(x_i, \theta)$ 的各阶样本矩函数依概率收敛于其各阶总体矩：

$$\frac{1}{n} \sum_{i=1}^n g_j(x_i, \theta) \xrightarrow{p} E[g_j(x_i, \theta)], j = 1, 2, \dots, k \quad (2.5)$$

最后，用样本矩函数代替其零总体矩，解 k 个方程构成的方程组，解出来的 $\hat{\theta}_{MM}$ 就是 θ 的经典矩估计量：

$$\frac{1}{n} \sum_{i=1}^n g_j(x_i, \hat{\theta}_{MM}) = 0, j = 1, 2, \dots, k \Rightarrow \hat{\theta}_{MM} \quad (2.6)$$

三 经典矩估计量渐近协方差的计算

这里考虑一般的情况，考虑向量值函数的经典矩估计量的渐近方差和协方差。令样本矩函数向量为：

如何构造这些向量值函数。如：
 $y = x\beta + \varepsilon_i$ ， x 是外生变量时。

$$\sum_{i=1}^n x_i \varepsilon_i = 0$$

这个说法有点不对。不是使 j 阶总体矩为零，而是存在 k 个矩条件。如 OLS 方法。

$$\frac{1}{n} \sum_{i=1}^n \underset{(k \times 1)}{\mathbf{g}}(x_i, \boldsymbol{\theta}) = \begin{bmatrix} \frac{1}{n} \sum_{i=1}^n g_1(x_i, \boldsymbol{\theta}) \\ \frac{1}{n} \sum_{i=1}^n g_2(x_i, \boldsymbol{\theta}) \\ \vdots \\ \frac{1}{n} \sum_{i=1}^n g_k(x_i, \boldsymbol{\theta}) \end{bmatrix} \quad (2.7)$$

根据中心极限定理 (CLT) 有:

$$\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n \underset{(k \times 1)}{\mathbf{g}}(x_i, \boldsymbol{\theta}) - \mathbf{0} \right) = \sqrt{n} \cdot \frac{1}{n} \sum_{i=1}^n \underset{(k \times 1)}{\mathbf{g}}(x_i, \boldsymbol{\theta}) \xrightarrow{d} N(0, \underset{(k \times k)}{\boldsymbol{\Omega}}) \quad (2.8)$$

其中协方差矩阵 $\underset{(k \times k)}{\boldsymbol{\Omega}}$ 为:

$$\underset{(k \times k)}{\boldsymbol{\Omega}} = E \left[\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n \underset{(k \times 1)}{\mathbf{g}}(x_i, \boldsymbol{\theta}) \right) \cdot \sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n \underset{(k \times 1)}{\mathbf{g}}(x_i, \boldsymbol{\theta}) \right)' \right] \quad (2.9)$$

$$\text{即:} \quad \frac{1}{n} \sum_{i=1}^n \underset{(k \times 1)}{\mathbf{g}}(x_i, \boldsymbol{\theta}) \xrightarrow{d} N\left(0, \frac{1}{n} \underset{(k \times k)}{\boldsymbol{\Omega}}\right) \quad (2.10)$$

$$\text{Var} \left(\frac{1}{n} \sum_{i=1}^n \underset{(k \times 1)}{\mathbf{g}}(x_i, \boldsymbol{\theta}) \right) = \frac{1}{n} \underset{(k \times k)}{\boldsymbol{\Omega}} \quad (2.11)$$

令 $\hat{\boldsymbol{\theta}} = \hat{\boldsymbol{\theta}}_{MM}$, 在真值 $\boldsymbol{\theta}$ 处, 对经典矩估计量 $\hat{\boldsymbol{\theta}}$ 的样本矩函数 $\frac{1}{n} \sum_{i=1}^n \underset{(k \times 1)}{\mathbf{g}}(x_i, \hat{\boldsymbol{\theta}})$ 进行一阶泰勒展开, 可得:

$$\mathbf{0} = \frac{1}{n} \sum_{i=1}^n \underset{(k \times 1)}{\mathbf{g}}(x_i, \hat{\boldsymbol{\theta}}) \approx \frac{1}{n} \sum_{i=1}^n \underset{(k \times 1)}{\mathbf{g}}(x_i, \boldsymbol{\theta}) + \left(\frac{1}{n} \sum_{i=1}^n \frac{\partial \underset{(k \times 1)}{\mathbf{g}}(x_i, \boldsymbol{\theta})}{\partial \boldsymbol{\theta}'} \right) (\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}) \quad (2.12)$$

令:

$$\underset{(k \times k)}{\mathbf{G}}(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n \frac{\partial \underset{(k \times 1)}{\mathbf{g}}(x_i, \boldsymbol{\theta})}{\partial \boldsymbol{\theta}'} \quad (2.13)$$

则:

$$\begin{aligned} (\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}) &= - \left(\frac{1}{n} \sum_{i=1}^n \frac{\partial \underset{(k \times 1)}{\mathbf{g}}(x_i, \boldsymbol{\theta})}{\partial \boldsymbol{\theta}'} \right)^{-1} \cdot \frac{1}{n} \sum_{i=1}^n \underset{(k \times 1)}{\mathbf{g}}(x_i, \boldsymbol{\theta}) \\ &= - \underset{(k \times k)}{\mathbf{G}}^{-1}(\boldsymbol{\theta}) \cdot \frac{1}{n} \sum_{i=1}^n \underset{(k \times 1)}{\mathbf{g}}(x_i, \boldsymbol{\theta}) \\ &\xrightarrow{d} - \underset{(k \times k)}{\mathbf{G}}^{-1}(\boldsymbol{\theta}) \cdot N\left(0, \frac{1}{n} \underset{(k \times k)}{\boldsymbol{\Omega}}\right) \\ &\xrightarrow{d} N\left\{0, \underset{(k \times k)}{\mathbf{G}}^{-1}(\boldsymbol{\theta}) \cdot \frac{1}{n} \underset{(k \times k)}{\boldsymbol{\Omega}} \cdot [\underset{(k \times k)}{\mathbf{G}}^{-1}(\boldsymbol{\theta})]'\right\} \end{aligned} \quad (2.14)$$

因此, 经典矩估计量的渐近协方差为:

$$\text{Var}(\hat{\boldsymbol{\theta}}_{MM}) = \frac{1}{n} \underset{(k \times k)}{\mathbf{G}}^{-1} \underset{(k \times k)}{\boldsymbol{\Omega}} (\underset{(k \times k)}{\mathbf{G}}^{-1})' \quad (2.15)$$

广义矩估计

— 广义矩方法

上节我们考虑了 k 个未知参数、 k 个矩条件的情形，下面假定我们遇到了 k 个未知参数、 m 个矩条件 ($m > k$) 的情形。

通过构造隐函数，使其各阶总体矩为 0，矩条件为如下形式：

How?如，IV。及此页下面这个例子

$$E \left[\underset{(m \times 1)}{\mathbf{g}(x_i, \boldsymbol{\theta})} \right] = E \begin{bmatrix} g_1(x_i, \boldsymbol{\theta}) \\ g_2(x_i, \boldsymbol{\theta}) \\ \vdots \\ g_m(x_i, \boldsymbol{\theta}) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}_{m \times 1} \quad (2.16)$$

包含参数 $\boldsymbol{\theta}$ 的零总体矩函数就是我们要求解的经济模型。用样本矩代替总体矩，则样本矩条件为：

$$\frac{1}{n} \sum_{i=1}^n \underset{(m \times 1)}{\mathbf{g}(x_i, \boldsymbol{\theta})} = \begin{bmatrix} \frac{1}{n} \sum_{i=1}^n g_1(x_i, \boldsymbol{\theta}) \\ \frac{1}{n} \sum_{i=1}^n g_2(x_i, \boldsymbol{\theta}) \\ \vdots \\ \frac{1}{n} \sum_{i=1}^n g_m(x_i, \boldsymbol{\theta}) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}_{m \times 1} \quad (2.17)$$

这里有 m 个方程，只有 k 个未知数，当 $m > k$ 时，上述模型是过度识别的。广义矩方法不是像经典矩方法那样，把多余的矩条件舍弃，而是把 m 个样本矩条件的 k 个线性组合设定为零。

找一个 k 行 m 列的矩阵 $\mathbf{A}_{(k \times m)}$ ，使它满足：

$$\underset{(k \times m)}{\mathbf{A}} \cdot \left[\frac{1}{n} \sum_{i=1}^n \underset{(m \times 1)}{\mathbf{g}(x_i, \boldsymbol{\theta})} \right] = \underset{(k \times 1)}{\mathbf{0}} \quad (2.18)$$

经典矩估计中，只取 k 阶样本矩

例如，对两个矩条件、一个参数 ($m=2, k=1$) 的情形，式 (2.18) 可写为：

$$\begin{bmatrix} a_1 & a_2 \end{bmatrix} \cdot \begin{pmatrix} \frac{1}{n} \sum_{i=1}^n g_1(x_i, \theta) \\ \frac{1}{n} \sum_{i=1}^n g_2(x_i, \theta) \end{pmatrix} = 0$$

即：

$$a_1 \frac{1}{n} \sum_{i=1}^n g_1(x_i, \theta) + a_2 \frac{1}{n} \sum_{i=1}^n g_2(x_i, \theta) = 0$$

解之可得广义矩估计量 $\hat{\theta}_{GMM}$ 。

$$\begin{aligned} E(\mathbf{X}\mathbf{U}) &= \mathbf{0}, \mathbf{X}=\mathbf{X}_1, \mathbf{X}_3; \\ E(\mathbf{U}) &= \mathbf{0}; \\ E(\mathbf{Z}\mathbf{U}) &= \mathbf{0}, \mathbf{Z}=\mathbf{Z}_1, \mathbf{Z}_2 \end{aligned}$$

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \mu_i \quad i=1, 2, \dots, n$$

- 如果 \mathbf{x}_2 为随机变量， \mathbf{z}_1 、 \mathbf{z}_2 为它的工具变量，GMM 关于参数估计量的矩条件为：

$$\begin{cases} \sum y_i - \sum (\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + \hat{\beta}_3 x_{3i}) = 0 \\ \sum y_i x_{1i} - \sum (\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + \hat{\beta}_3 x_{3i}) x_{1i} = 0 \\ \sum y_i z_{1i} - \sum (\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + \hat{\beta}_3 x_{3i}) z_{1i} = 0 \\ \sum y_i z_{2i} - \sum (\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + \hat{\beta}_3 x_{3i}) z_{2i} = 0 \\ \sum y_i x_{3i} - \sum (\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + \hat{\beta}_3 x_{3i}) x_{3i} = 0 \end{cases}$$

5个等于0的矩条件，求解4个参数

该方程组是如何得到的？

如何求解该方程组？

选择不同的矩阵 $\mathbf{A}_{(k \times m)}$ ，将得到不同的 GMM 估计量。矩阵 \mathbf{A} 类似于一个工具变量 (IV) 矩阵，选择不同的矩阵 \mathbf{A} ，将得到不同的估计量。当 $m = k$ 时，上述模型是恰好识别的，此时选择任何可逆矩阵 \mathbf{A} ，都将得到相同的 GMM 估计量，因为在这种情形下矩阵 \mathbf{A} 是多余的，可以消去。

该问题可以转化为一个最小化目标函数的问题，从而把矩阵 $\mathbf{A}_{(k \times m)}$ 的选择转化为对称权矩阵 $\mathbf{W}_{(m \times m)}$ 的最优选择。令目标函数（或损失函数）为：

$$Loss = \left[\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta}) \right]'_{(1 \times m)} \mathbf{W}_{(m \times m)} \left[\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta}) \right]_{(m \times 1)} \quad (2.19)$$

最小化该损失函数，解出来的 $\boldsymbol{\theta}$ 就是广义矩估计量 $\hat{\boldsymbol{\theta}}_{GMM}$ ，即：

$$\hat{\boldsymbol{\theta}}_{GMM} = \arg \min_{\boldsymbol{\theta}} \left[\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta}) \right]' \mathbf{W} \left[\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta}) \right] \quad (2.20)$$

为了书写方便，令 $\hat{\boldsymbol{\theta}} = \hat{\boldsymbol{\theta}}_{GMM}$ ，最小化损失函数的 k 个一阶条件 (FOC) 为：

$$\left[\frac{1}{n} \sum_{i=1}^n \frac{\partial \mathbf{g}(x_i, \hat{\boldsymbol{\theta}})}{\partial \boldsymbol{\theta}'} \right]'_{(k \times m)} \mathbf{W}_{(m \times m)} \left[\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \hat{\boldsymbol{\theta}}) \right]_{(m \times 1)} = \mathbf{0}_{(k \times 1)} \quad (2.21)$$

令：

$$\mathbf{G}(\boldsymbol{\theta})_{(m \times k)} = \frac{1}{n} \sum_{i=1}^n \frac{\partial \mathbf{g}(x_i, \boldsymbol{\theta})}{\partial \boldsymbol{\theta}'} \quad (2.22)$$

与权矩阵 \mathbf{W} 相对应的矩阵 \mathbf{A} ，便可以通过下面的关系式得到：

$$\mathbf{A}_{(k \times m)} = \left[\frac{1}{n} \sum_{i=1}^n \frac{\partial \mathbf{g}(x_i, \hat{\boldsymbol{\theta}})}{\partial \boldsymbol{\theta}'} \right]'_{(k \times m)} \mathbf{W}_{(m \times m)} = \mathbf{G}'(\hat{\boldsymbol{\theta}})_{(k \times m)} \mathbf{W}_{(m \times m)} \quad (2.23)$$

权矩阵 \mathbf{W} 的选择标准，应使广义矩估计量 $\hat{\boldsymbol{\theta}}_{GMM}$ 最有效。最优权矩阵 \mathbf{W} 的选择将在下一节中专门论述。

二 一般广义矩估计量的性质

假定数据是独立同分布 (i. i. d.) 的，在大样本情况下，一般 GMM

估计量具有一致性和渐近正态性。

1. 一致性

$$plim(\hat{\boldsymbol{\theta}}_{GMM}) = \boldsymbol{\theta} \quad (2.24)$$

$$\hat{\boldsymbol{\theta}}_{GMM} \xrightarrow{p} \boldsymbol{\theta} \quad (2.25)$$

2. 渐近正态性

$$\sqrt{n}(\hat{\boldsymbol{\theta}}_{GMM} - \boldsymbol{\theta}) \xrightarrow{d} N\{\mathbf{0}, [\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} \mathbf{G}'\mathbf{W}\Omega\mathbf{W}\mathbf{G}[\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1}\} \quad (2.26)$$

$$\text{Var}(\hat{\boldsymbol{\theta}}_{GMM}) = \frac{1}{n} [\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} \mathbf{G}'\mathbf{W}\Omega\mathbf{W}\mathbf{G}[\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} \quad (2.27)$$

证明：

令 $\hat{\boldsymbol{\theta}} = \hat{\boldsymbol{\theta}}_{GMM}$ ，根据式 (2.21)，最小化损失函数的一阶条件为：

$$\left[\frac{1}{n} \sum_{i=1}^n \frac{\partial \mathbf{g}(x_i, \hat{\boldsymbol{\theta}})}{\partial \boldsymbol{\theta}'} \right]'_{(k \times m)} \mathbf{W}_{(m \times m)} \left[\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \hat{\boldsymbol{\theta}}) \right]_{(m \times 1)} = \mathbf{0}_{(k \times 1)}$$

在真值 $\boldsymbol{\theta}$ 处，对一般广义矩估计量 $\hat{\boldsymbol{\theta}}$ 的样本矩函数 $\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \hat{\boldsymbol{\theta}})$ 进行一阶泰勒展开，可得：

$$\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \hat{\boldsymbol{\theta}})_{(m \times 1)} \approx \frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta})_{(m \times 1)} + \left(\frac{1}{n} \sum_{i=1}^n \frac{\partial \mathbf{g}(x_i, \boldsymbol{\theta})}{\partial \boldsymbol{\theta}'} \right)_{(m \times k)} (\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})_{(k \times 1)} \quad (2.28)$$

损失函数？

对称权矩阵是 $m \times m$ 阶的 \mathbf{W} 矩阵反映了 \mathbf{g} 的重要性

如，以下说明以某一标准选择权矩阵

关于权矩阵的选择，是 GMM 估计方法的一个核心问题。

$$\hat{\beta} = \arg \min (\mathbf{m}(\beta)' \mathbf{W}^{-1} \mathbf{m}(\beta))$$

权矩阵可根据每个样本矩条件估计的精确程度来设置（用方差来度量）。例如，对估计较精确的矩条件给予较大的权重，对估计较不精确的矩条件给予较小的权重。

$$\mathbf{W} = \frac{1}{n^2} \sum_i \sum_j \text{Cov}[Z_i \varepsilon_i, Z_j \varepsilon_j]$$

如此构造权矩阵体现了上述设置权矩阵的原则。类似于加权最小二乘法

权矩阵调整的是 J 个矩条件之间的关系，而不是 n 个样本点之间的关系。

\mathbf{W} 应是 $[(1/n)\text{Var}(\mathbf{Z}'\boldsymbol{\varepsilon})]^{-1}$ 的一致估计。

$$\hat{\beta} = \arg \min (\mathbf{m}(\beta)'_{(1 \times J)} \mathbf{W}_{(J \times J)}^{-1} \mathbf{m}(\beta)_{(J \times 1)})$$

于是最小化函数的一阶条件可写为：

$$\begin{aligned}
 & \left[\frac{1}{n} \sum_{i=1}^n \frac{\partial \mathbf{g}(x_i, \hat{\boldsymbol{\theta}})}{\partial \boldsymbol{\theta}'} \right]'_{(k \times m)} \mathbf{W}_{(m \times m)} \left[\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \hat{\boldsymbol{\theta}}) \right]_{(m \times 1)} \\
 &= \left[\frac{1}{n} \sum_{i=1}^n \frac{\partial \mathbf{g}(x_i, \hat{\boldsymbol{\theta}})}{\partial \boldsymbol{\theta}'} \right]'_{(k \times m)} \mathbf{W}_{(m \times m)} \left[\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta}) \right]_{(m \times 1)} \\
 &+ \left[\frac{1}{n} \sum_{i=1}^n \frac{\partial \mathbf{g}(x_i, \hat{\boldsymbol{\theta}})}{\partial \boldsymbol{\theta}'} \right]'_{(k \times m)} \mathbf{W}_{(m \times m)} \left(\frac{1}{n} \sum_{i=1}^n \frac{\partial \mathbf{g}(x_i, \boldsymbol{\theta})}{\partial \boldsymbol{\theta}'} \right)_{(m \times k)} (\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})_{(k \times 1)} \\
 &= \mathbf{G}'(\hat{\boldsymbol{\theta}})_{(k \times m)} \cdot \mathbf{W}_{(m \times m)} \cdot \left[\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta}) \right]_{(m \times 1)} + \mathbf{G}'(\hat{\boldsymbol{\theta}})_{(k \times m)} \cdot \mathbf{W}_{(m \times m)} \cdot \mathbf{G}(\boldsymbol{\theta})_{(m \times k)} \cdot (\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})_{(k \times 1)} \\
 &= \mathbf{0}_{(k \times 1)}
 \end{aligned}$$

故有：

$$\begin{aligned}
 \sqrt{n}(\hat{\boldsymbol{\theta}}_{(k \times 1)} - \boldsymbol{\theta}) &= - \left[\mathbf{G}'(\hat{\boldsymbol{\theta}})_{(k \times m)} \cdot \mathbf{W}_{(m \times m)} \cdot \mathbf{G}(\boldsymbol{\theta})_{(m \times k)} \right]^{-1} \mathbf{G}'(\hat{\boldsymbol{\theta}})_{(k \times m)} \cdot \mathbf{W}_{(m \times m)} \\
 &\cdot \left[\sqrt{n} \cdot \frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta}) \right]_{(m \times 1)} \quad (2.29)
 \end{aligned}$$

因为：

$$\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta})_{(m \times 1)} - \mathbf{0} \right) = \sqrt{n} \cdot \frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta})_{(m \times 1)} \xrightarrow{d} N(\mathbf{0}, \boldsymbol{\Omega}_{(m \times m)}) \quad (2.30)$$

其中样本矩的协方差矩阵 $\boldsymbol{\Omega}_{(m \times m)}$ 为：

$$\boldsymbol{\Omega}_{(m \times m)} = E \left[\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta}) \right) \cdot \sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta}) \right)' \right] \quad (2.31)$$

所以：

$$\begin{aligned}
 & \sqrt{n}(\hat{\boldsymbol{\theta}}_{(k \times 1)} - \boldsymbol{\theta}) \\
 &= - \left[\mathbf{G}'(\hat{\boldsymbol{\theta}})_{(k \times m)} \cdot \mathbf{W}_{(m \times m)} \cdot \mathbf{G}(\boldsymbol{\theta})_{(m \times k)} \right]^{-1} \mathbf{G}'(\hat{\boldsymbol{\theta}})_{(k \times m)} \cdot \mathbf{W}_{(m \times m)} \cdot \left[\sqrt{n} \cdot \frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta}) \right]_{(m \times 1)} \\
 &\xrightarrow{d} - [\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} \mathbf{G}'\mathbf{W} \cdot N(\mathbf{0}, \boldsymbol{\Omega}) \\
 &\xrightarrow{d} N\{\mathbf{0}, [\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} \mathbf{G}'\mathbf{W}\boldsymbol{\Omega}\mathbf{W}\mathbf{G}[\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1}\}
 \end{aligned} \quad (2.32)$$

因此，对一般权矩阵 \mathbf{W} ，一般广义矩估计量的渐近协方差为：

$$\text{Var}(\hat{\boldsymbol{\theta}}_{GMM}) = \frac{1}{n} [\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} \mathbf{G}'\mathbf{W}\boldsymbol{\Omega}\mathbf{W}\mathbf{G}[\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} \quad (2.33)$$

第三节 最优权矩阵与最优 GMM

采用最优权矩阵的 GMM 称为“最优 GMM”，最优权矩阵 \mathbf{W} 的选择，应能使广义矩估计量 $\hat{\boldsymbol{\theta}}_{GMM}$ 最有效。给定一组矩条件，最优权矩阵规定了如何运用这些矩条件来尽可能精确地估计 $\boldsymbol{\theta}$ 。“最优 GMM”并不能告诉我们在估计过程中使用了哪些矩条件。一般来说，在估计过程中，使用的有效的矩条件越多，GMM 估计量越有效。

一 最优权矩阵的选择

1. 最优权矩阵 \mathbf{W} 及最优 GMM 估计量的渐近协方差

首先我们给出最优权矩阵 \mathbf{W} 的结果，然后再证明这个结论。

对任意一个非奇异矩阵 \mathbf{e} ，矩阵 \mathbf{A} 的最优选择是：

$$\mathbf{A}_{(k \times m)} = \mathbf{e}_{(k \times k)} \mathbf{G}'_{(k \times m)} \boldsymbol{\Omega}^{-1}_{(m \times m)} \quad (2.34)$$

其中 $\boldsymbol{\Omega}_{(m \times m)}$ 是总体矩 $\sqrt{n}E[\mathbf{g}(x_i, \boldsymbol{\theta})]$ 或样本矩 $\sqrt{n}\left(\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta})\right)$ 的渐近

协方差矩阵。

考虑一种简单的情况，当 $\mathbf{e}_{(k \times k)} = \mathbf{I}_{(k \times k)}$ 时，这意味着：

$$\mathbf{A}_{(k \times m)}^* = \mathbf{G}_{(k \times m)}' \mathbf{\Omega}_{(m \times m)}^{-1} \quad (2.35)$$

是最优的。从上节的定义知 $\mathbf{A} = \mathbf{G}'\mathbf{W}$ ，因此最优权矩阵 \mathbf{W} 应满足：

$$\mathbf{G}'\mathbf{\Omega}^{-1} = \mathbf{G}'\mathbf{W} \Rightarrow \mathbf{W} = \mathbf{\Omega}^{-1} \quad (2.36)$$

这里， $\mathbf{G}'\mathbf{\Omega}^{-1} = \mathbf{G}'\mathbf{W}$ 是 \mathbf{W} 为最优权矩阵的充分必要条件，而 $\mathbf{W} = \mathbf{\Omega}^{-1}$ 只是其充分条件。即：

$$\mathbf{G}'\mathbf{\Omega}^{-1} = \mathbf{G}'\mathbf{W} \Leftrightarrow \mathbf{W} \text{ 是最优权矩阵} \quad (2.37)$$

$$\mathbf{W} = \mathbf{\Omega}^{-1} \Rightarrow \mathbf{W} \text{ 是最优权矩阵} \quad (2.38)$$

在最优权矩阵 $\mathbf{W} = \mathbf{\Omega}^{-1}$ 条件下， $\sqrt{n}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})$ 依分布收敛于 $N\{\mathbf{0}, [\mathbf{G}'\mathbf{\Omega}^{-1}\mathbf{G}]^{-1}\}$ ，即：

$$\begin{aligned} \sqrt{n}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}) &\xrightarrow{d} N\{\mathbf{0}, [\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1}\mathbf{G}'\mathbf{W}\mathbf{\Omega}\mathbf{W}\mathbf{G}[\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1}\} \\ &= N\{\mathbf{0}, [\mathbf{G}'\mathbf{\Omega}^{-1}\mathbf{G}]^{-1}\} \end{aligned} \quad (2.39)$$

$$\text{Var}(\hat{\boldsymbol{\theta}}_{GMM}) = \frac{1}{n}[\mathbf{G}'\mathbf{\Omega}^{-1}\mathbf{G}]^{-1} \quad (2.40)$$

2. 最优 GMM 估计量最有效的证明

最优 GMM 估计量最有效可以用反证法来证明：选择其他任何的一般权矩阵 $\mathbf{W} \neq \mathbf{\Omega}^{-1}$ 时 $\sqrt{n}\hat{\boldsymbol{\theta}}$ 的渐近协方差与选择最优权矩阵 $\mathbf{W} = \mathbf{\Omega}^{-1}$ 时的 $\sqrt{n}\hat{\boldsymbol{\theta}}$ 渐近协方差之差 $[\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1}\mathbf{G}'\mathbf{W}\mathbf{\Omega}\mathbf{W}\mathbf{G}[\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} - [\mathbf{G}'\mathbf{\Omega}^{-1}\mathbf{G}]^{-1}$ 总是半正定的。

证明如下：

$$\begin{aligned} &[\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1}\mathbf{G}'\mathbf{W}\mathbf{\Omega}\mathbf{W}\mathbf{G}[\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} - [\mathbf{G}'\mathbf{\Omega}^{-1}\mathbf{G}]^{-1} \\ &= [\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} \{ \mathbf{G}'\mathbf{W}\mathbf{\Omega}\mathbf{W}\mathbf{G} - \mathbf{G}'\mathbf{W}\mathbf{G}[\mathbf{G}'\mathbf{\Omega}^{-1}\mathbf{G}]^{-1}\mathbf{G}'\mathbf{W}\mathbf{G} \} [\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} \end{aligned} \quad (2.41)$$

设 $\mathbf{Z}_{(m \times 1)}$ 为满足：

$$\mathbf{\Omega}_{(m \times m)} = E(\mathbf{Z}_{(m \times 1)}\mathbf{Z}_{(m \times 1)}') \quad (2.42)$$

的任意随机向量，令：

$$\mathbf{m}_{(k \times 1)} = \mathbf{G}_{(k \times m)}' \mathbf{W}_{(m \times m)} \mathbf{Z}_{(m \times 1)} \quad (2.43)$$

$$\bar{\mathbf{m}}_{(k \times 1)} = \mathbf{G}_{(k \times m)}' \mathbf{\Omega}_{(m \times m)}^{-1} \mathbf{Z}_{(m \times 1)} \quad (2.44)$$

$$\mathbf{U} = \mathbf{m} - E[\mathbf{m}\mathbf{m}'] (E[\bar{\mathbf{m}}\bar{\mathbf{m}}'])^{-1} \bar{\mathbf{m}} \quad (2.45)$$

于是：

$$\begin{aligned} &E[\mathbf{U}\mathbf{U}'] \\ &= E[\mathbf{m}\mathbf{m}'] - E[\mathbf{m}\bar{\mathbf{m}}'] (E[\bar{\mathbf{m}}\bar{\mathbf{m}}'])^{-1} E[\bar{\mathbf{m}}\mathbf{m}'] \\ &\quad - E[\mathbf{m}\bar{\mathbf{m}}'] (E[\bar{\mathbf{m}}\bar{\mathbf{m}}'])^{-1} E[\bar{\mathbf{m}}\mathbf{m}'] \\ &\quad + E[\mathbf{m}\bar{\mathbf{m}}'] (E[\bar{\mathbf{m}}\bar{\mathbf{m}}'])^{-1} E[\bar{\mathbf{m}}\bar{\mathbf{m}}'] (E[\bar{\mathbf{m}}\bar{\mathbf{m}}'])^{-1} E[\bar{\mathbf{m}}\mathbf{m}'] \\ &= E[\mathbf{m}\mathbf{m}'] - E[\mathbf{m}\bar{\mathbf{m}}'] (E[\bar{\mathbf{m}}\bar{\mathbf{m}}'])^{-1} E[\bar{\mathbf{m}}\mathbf{m}'] \\ &= \mathbf{G}'\mathbf{W} \cdot E(\mathbf{Z}\mathbf{Z}') \cdot \mathbf{W}\mathbf{G} - \mathbf{G}'\mathbf{W} \cdot E(\mathbf{Z}\mathbf{Z}') \cdot \\ &\quad \mathbf{\Omega}^{-1}\mathbf{G}[\mathbf{G}'\mathbf{\Omega}^{-1} \cdot E(\mathbf{Z}\mathbf{Z}') \cdot \mathbf{\Omega}^{-1}\mathbf{G}]^{-1}\mathbf{G}'\mathbf{\Omega}^{-1} \cdot E(\mathbf{Z}\mathbf{Z}') \cdot \mathbf{W}\mathbf{G} \\ &= \mathbf{G}'\mathbf{W}\mathbf{\Omega}\mathbf{W}\mathbf{G} - \mathbf{G}'\mathbf{W}\mathbf{G}[\mathbf{G}'\mathbf{\Omega}^{-1}\mathbf{G}]^{-1}\mathbf{G}'\mathbf{W}\mathbf{G} \end{aligned} \quad (2.46)$$

从而：

$$\begin{aligned} &[\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1}\mathbf{G}'\mathbf{W}\mathbf{\Omega}\mathbf{W}\mathbf{G}[\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} - [\mathbf{G}'\mathbf{\Omega}^{-1}\mathbf{G}]^{-1} \\ &= [\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} \cdot E[\mathbf{U}\mathbf{U}'] \cdot [\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} \end{aligned} \quad (2.47)$$

一般地，如果矩阵 \mathbf{P} 是半正定的，矩阵 \mathbf{Q} 是非奇异的，则 $\mathbf{Q}'\mathbf{P}\mathbf{Q}$ 是半正定的。由于 $E[\mathbf{U}\mathbf{U}']$ 是半正定的，因此 $[\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} \cdot E[\mathbf{U}\mathbf{U}'] \cdot [\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1}$ 也是半正定的，从而 $[\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1}\mathbf{G}'\mathbf{W}\mathbf{\Omega}\mathbf{W}\mathbf{G}[\mathbf{G}'\mathbf{W}\mathbf{G}]^{-1} - [\mathbf{G}'\mathbf{\Omega}^{-1}\mathbf{G}]^{-1}$ 是半正定的。这就证明了“最优 GMM”估计量最有效的结论。

二 最优 GMM 估计示例

设 (x_i, y_i) 独立同分布，观测值样本为 (x_i, y_i) , $i = 1, 2, \dots, n$ ，要估计的模型为： $E y_i = \mu$ 。已知 $E x_i = 0$ ，如何构造一个有效的广义矩估计量来估计参数 μ ？

总体矩条件为： $E[\mathbf{g}(\mu)] = \mathbf{0}$ ，其中：

$$\mathbf{g}(\mu) = \begin{pmatrix} y_i - \mu \\ x_i \end{pmatrix} \quad (2.48)$$

样本矩条件为：

$$\frac{1}{n} \sum_{i=1}^n \mathbf{g}(\mu) = \begin{pmatrix} \frac{1}{n} \sum_{i=1}^n y_i - \mu \\ \frac{1}{n} \sum_{i=1}^n x_i \end{pmatrix} = \mathbf{0} \quad (2.49)$$

这里有两个矩条件，一个参数，因此模型是过度识别的。令总体矩的渐近协方差矩阵为：

$$\begin{aligned} \Omega &= E[\sqrt{n} \mathbf{g}(\mu) \cdot \sqrt{n} \mathbf{g}'(\mu)] \\ &= n \begin{pmatrix} E(y_i - \mu)^2 & E[x_i(y_i - \mu)] \\ E[x_i(y_i - \mu)] & E x_i^2 \end{pmatrix} \quad (2.50) \\ &= n \begin{pmatrix} \sigma_y^2 & \sigma_{xy} \\ \sigma_{xy} & \sigma_x^2 \end{pmatrix} \end{aligned}$$

由于：

$$\begin{aligned} \hat{\sigma}_y^2 &= \frac{1}{n} \sum_{i=1}^n \left(y_i - \frac{1}{n} \sum_{i=1}^n y_i \right)^2 \\ \hat{\sigma}_x^2 &= \frac{1}{n} \sum_{i=1}^n x_i^2 \\ \hat{\sigma}_{xy} &= \frac{1}{n} \sum_{i=1}^n \left(y_i - \frac{1}{n} \sum_{i=1}^n y_i \right) x_i \end{aligned}$$

因此 Ω 的样本估计值为：

$$\begin{aligned} \hat{\Omega} &= n \begin{pmatrix} \hat{\sigma}_y^2 & \hat{\sigma}_{xy} \\ \hat{\sigma}_{xy} & \hat{\sigma}_x^2 \end{pmatrix} \\ &= n \begin{pmatrix} \frac{1}{n} \sum_{i=1}^n \left(y_i - \frac{1}{n} \sum_{i=1}^n y_i \right)^2 & \frac{1}{n} \sum_{i=1}^n \left(y_i - \frac{1}{n} \sum_{i=1}^n y_i \right) x_i \\ \frac{1}{n} \sum_{i=1}^n \left(y_i - \frac{1}{n} \sum_{i=1}^n y_i \right) x_i & \frac{1}{n} \sum_{i=1}^n x_i^2 \end{pmatrix} \end{aligned}$$

取最优权矩阵：

$$\mathbf{W} = \Omega^{-1} = \frac{1}{n(\hat{\sigma}_y^2 \hat{\sigma}_x^2 - \hat{\sigma}_{xy}^2)} \begin{pmatrix} \hat{\sigma}_x^2 & -\hat{\sigma}_{xy} \\ -\hat{\sigma}_{xy} & \hat{\sigma}_y^2 \end{pmatrix} \quad (2.51)$$

最小化的目标函数为：

$$Loss = \left[\frac{1}{n} \sum_{i=1}^n \mathbf{g}(\mu) \right]' \Omega^{-1} \left[\frac{1}{n} \sum_{i=1}^n \mathbf{g}(\mu) \right]$$

$$\begin{aligned}
&= \frac{1}{n(\hat{\sigma}_y^2 \hat{\sigma}_x^2 - \hat{\sigma}_{xy}^2)} \left(\frac{1}{n} \sum_{i=1}^n y_i - \mu, \frac{1}{n} \sum_{i=1}^n x_i \right) \begin{pmatrix} \hat{\sigma}_x^2 & -\hat{\sigma}_{xy} \\ -\hat{\sigma}_{xy} & \hat{\sigma}_y^2 \end{pmatrix} \begin{pmatrix} \frac{1}{n} \sum_{i=1}^n y_i - \mu \\ \frac{1}{n} \sum_{i=1}^n x_i \end{pmatrix} \\
&= \frac{1}{n(\hat{\sigma}_y^2 \hat{\sigma}_x^2 - \hat{\sigma}_{xy}^2)} \left[\hat{\sigma}_x^2 \left(\frac{1}{n} \sum_{i=1}^n y_i - \mu \right)^2 - 2\hat{\sigma}_{xy} \left(\frac{1}{n} \sum_{i=1}^n y_i - \mu \right) \right. \\
&\quad \left. \left(\frac{1}{n} \sum_{i=1}^n x_i \right) + \hat{\sigma}_y^2 \left(\frac{1}{n} \sum_{i=1}^n x_i \right)^2 \right] \quad (2.52)
\end{aligned}$$

解其一阶条件可得：

$$\begin{aligned}
\hat{\mu}_{GMM} &= \arg \min_{\mu} Loss \\
&= \frac{1}{n} \sum_{i=1}^n y_i - \frac{\hat{\sigma}_{xy}}{\hat{\sigma}_x^2} \left(\frac{1}{n} \sum_{i=1}^n x_i \right)
\end{aligned}$$

三 最优 GMM 估计量数值算法的步骤

在经典矩方法中，有 k 个未知参数， k 个矩条件。在广义矩方法中，有 k 个未知参数， m 个矩条件 ($m > k$)。假定向量值函数 $\mathbf{g}(x_i, \boldsymbol{\theta})$ 的 j 阶总体矩为零，即： $E[\mathbf{g}_j(x_i, \boldsymbol{\theta})] = 0, j = 1, 2, \dots, m$ 。用 $\mathbf{g}'(x_i, \boldsymbol{\theta})$ 表示 $\mathbf{g}(x_i, \boldsymbol{\theta})$ 的转置：

$$\mathbf{g}(x_i, \boldsymbol{\theta}) = \begin{bmatrix} g_1(x_i, \boldsymbol{\theta}) \\ g_2(x_i, \boldsymbol{\theta}) \\ \vdots \\ g_m(x_i, \boldsymbol{\theta}) \end{bmatrix} \quad (2.53)$$

$$\mathbf{g}'(x_i, \boldsymbol{\theta}) = [g_1(x_i, \boldsymbol{\theta}), g_2(x_i, \boldsymbol{\theta}), \dots, g_m(x_i, \boldsymbol{\theta})] \quad (2.54)$$

对协方差矩阵 $\boldsymbol{\Omega}_{(m \times m)}$ 进行如下变换：

$$\begin{aligned}
\boldsymbol{\Omega}_{(m \times m)} &= E \left[\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta}) \right) \cdot \sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta}) \right)' \right] \\
&= E \left[\frac{1}{n} \left(\sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta}) \right) \cdot \left(\sum_{i=1}^n \mathbf{g}(x_i, \boldsymbol{\theta}) \right)' \right] \\
&= E \left\{ \frac{1}{n} \sum_{i=1}^n [\mathbf{g}(x_i, \boldsymbol{\theta}) \cdot \mathbf{g}'(x_i, \boldsymbol{\theta})] + \frac{1}{n} \sum_{i=1}^n \sum_{\substack{j=1 \\ j \neq i}}^n [\mathbf{g}(x_i, \boldsymbol{\theta}) \cdot \mathbf{g}'(x_j, \boldsymbol{\theta})] \right\} \\
&= \frac{1}{n} \sum_{i=1}^n E[\mathbf{g}(x_i, \boldsymbol{\theta}) \cdot \mathbf{g}'(x_i, \boldsymbol{\theta})] \quad (2.55) \\
&\quad + \frac{1}{n} \sum_{l=1}^{n-1} \sum_{i=l+1}^n \{ E[\mathbf{g}(x_i, \boldsymbol{\theta}) \cdot \mathbf{g}'(x_{i-l}, \boldsymbol{\theta})] + E[\mathbf{g}(x_{i-l}, \boldsymbol{\theta}) \cdot \mathbf{g}'(x_i, \boldsymbol{\theta})] \} \\
&\quad + \frac{1}{n} \sum_{l=1}^{n-1} \sum_{i=l+1}^n \{ E[\mathbf{g}(x_i, \boldsymbol{\theta}) \cdot \mathbf{g}'(x_{i-l}, \boldsymbol{\theta})] + E[\mathbf{g}(x_{i-l}, \boldsymbol{\theta}) \cdot \mathbf{g}'(x_i, \boldsymbol{\theta})] \}
\end{aligned}$$

一旦给定 $\boldsymbol{\theta}$ 的一个初值 $\hat{\boldsymbol{\theta}}_0$ ，且 $\hat{\boldsymbol{\theta}}_0$ 是 $\boldsymbol{\theta}$ 的一个一致性估计，基于上面的结果，考虑到 $\mathbf{g}(x_i, \boldsymbol{\theta})$ 之间的序列相关性，纽维和韦斯特 (Newey & West, 1987) 建议采用下面的算法来估计 $\hat{\boldsymbol{\Omega}}_{(m \times m)}$ ：

$$\begin{aligned}
\hat{\boldsymbol{\Omega}} &= \frac{1}{n} \sum_{i=1}^n [\mathbf{g}(x_i, \hat{\boldsymbol{\theta}}_0) \cdot \mathbf{g}'(x_i, \hat{\boldsymbol{\theta}}_0)] \\
&\quad + \frac{1}{n} \sum_{l=1}^L w(l) \sum_{i=l+1}^n [\mathbf{g}(x_i, \hat{\boldsymbol{\theta}}_0) \cdot \mathbf{g}'(x_{i-l}, \hat{\boldsymbol{\theta}}_0) + \mathbf{g}(x_{i-l}, \hat{\boldsymbol{\theta}}_0) \cdot \mathbf{g}'(x_i, \hat{\boldsymbol{\theta}}_0)] \quad (2.56)
\end{aligned}$$

其中：

$$w(l) = 1 - \frac{l}{L+1} \quad (2.57)$$

最大滞后期 L 必须事先确定, 当滞后期大于 L 时, 自相关小到可以忽略的程度。 L 应满足:

$$\lim_{n \rightarrow \infty} \frac{L}{\sqrt{n}} = 0 \quad (2.58)$$

于是, 最优 GMM 估计量可以通过下列数值算法来实现:

第一步: 计算 θ 的初值 $\hat{\theta}_0$ 及 Ω 的初值 $\hat{\Omega}_0$, 初始时令权矩阵为单位矩阵, 即 $W_0 = I$, 把此时 GMM 估计量作为 θ 的初值 $\hat{\theta}_0$, 即:

$$\begin{aligned} \hat{\theta}_0 &= \arg \min_{\theta} \left[\frac{1}{n} \sum_{i=1}^n g(x_i, \theta) \right]' W \left[\frac{1}{n} \sum_{i=1}^n g(x_i, \theta) \right] \\ &= \arg \min_{\theta} \left[\frac{1}{n} \sum_{i=1}^n g(x_i, \theta) \right]' \left[\frac{1}{n} \sum_{i=1}^n g(x_i, \theta) \right] \end{aligned} \quad (2.59)$$

在 $\hat{\theta}_0$ 处, 运用纽维和韦斯特方法估计 $\hat{\Omega}_0$, 并得到最优权矩阵 W 的一个初始的一致估计量 $\hat{W}_1 = \hat{\Omega}_0^{-1}$ 。

第二步: 通过求解下面的最优化问题, 得到与上面的最优权矩阵 $\hat{\Omega}_0^{-1}$ 相对应的 GMM 估计量 $\hat{\theta}_1$:

$$\hat{\theta}_1 = \arg \min_{\theta} \left[\frac{1}{n} \sum_{i=1}^n g(x_i, \theta) \right]' \hat{\Omega}_0^{-1} \left[\frac{1}{n} \sum_{i=1}^n g(x_i, \theta) \right] \quad (2.60)$$

第三步: 在 $\hat{\theta}_1$ 处, 运用纽维和韦斯特公式估计 $\hat{\Omega}_1$, 并得到最优权矩阵 W 的一个更新估计量 $\hat{W}_2 = \hat{\Omega}_1^{-1}$ 。

在 $\hat{\theta}_1$ 处, 计算 G 的一致估计量:

$$\hat{G} = E \left[\frac{\partial g(x_i, \hat{\theta}_1)}{\partial \theta'} \right] = \frac{1}{n} \sum_{i=1}^n \frac{\partial g(x_i, \hat{\theta}_1)}{\partial \theta'} \quad (2.61)$$

从而得到:

$$\text{Var}(\hat{\theta}_{GMM}) = \frac{1}{n} [G' \Omega^{-1} G]^{-1} \quad (2.62)$$

第四步: 进行迭代。把新的 $\hat{\theta}_1$ 和新的 $\hat{\Omega}_1$ 作为初值, 重复第二步和第三步。这一过程可迭代下去, 直至收敛 (比如 $\hat{\theta}_{j+1} \approx \hat{\theta}_j$) 为止, 便得到了最优 GMM 估计量及其渐近协方差。

过度识别约束检验 $Y=X\beta$

假设参数个数为 k 个, 当解释变量中包含随机变量即 $E(Xu) \neq 0$ 时, 应采用工具变量 (IV) 法。假设工具变量为 Z , 它满足: $E(Zu) = 0$

当工具变量个数 m 等于 k 时, 可采用普通的工具变量法进行参数估计。当工具变量个数 m 大于 k 时, 存在 m 个矩条件, k 个参数。假设这 m 个矩条件都是有效的, 可以用 GMM 进行估计, 目标函数为:

$$\min \left(\frac{1}{n} \sum_i (y_i - X_i \beta) Z_i \right)' \Omega^{-1} \left(\frac{1}{n} \sum_i (y_i - X_i \beta) Z_i \right) \quad (2.63)$$

其中最优权矩阵为:

$$\begin{aligned} \Omega_{(m \times m)} &= E \left[\sqrt{n} \left(\frac{1}{n} \sum_i (y_i - X_i \beta) Z_i \right) \cdot \sqrt{n} \left(\frac{1}{n} \sum_i (y_i - X_i \beta) Z_i \right)' \right] \\ &= E \left[\frac{1}{n} \sum_i (u_i Z_i) \cdot \sum_i (u_i Z_i)' \right] \end{aligned} \quad (2.64)$$

当随机误差项 u 满足同方差假定时, 令 $u_i^2 = \sigma^2$, 则最优权矩阵可简化为:

$$\Omega = E \left[\frac{1}{n} \sum_i (u_i Z_i) \cdot \sum_i (u_i Z_i)' \right] = \frac{\sigma^2}{n} Z' Z \quad (2.65)$$

于是目标函数变为：

$$\min \frac{\sigma^2}{n} \left(\frac{1}{n} \mathbf{Z}' (Y - \mathbf{X}\beta) \right)' (\mathbf{Z}'\mathbf{Z})^{-1} \left(\frac{1}{n} \mathbf{Z}' (Y - \mathbf{X}\beta) \right) \quad (2.66)$$

一阶条件为：

$$(\mathbf{X}'\mathbf{Z})(\mathbf{Z}'\mathbf{Z})^{-1}(\mathbf{Z}'(Y - \mathbf{X}\hat{\beta})) = 0 \quad (2.67)$$

于是可得：

$$\hat{\beta}_{GMM} = [(\mathbf{X}'\mathbf{Z})(\mathbf{Z}'\mathbf{Z})^{-1}(\mathbf{Z}'\mathbf{X})]^{-1}[(\mathbf{X}'\mathbf{Z})(\mathbf{Z}'\mathbf{Z})^{-1}(\mathbf{Z}'\mathbf{Y})] \quad (2.68)$$

令 $\mathbf{P}_Z = \mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'$, $\hat{\mathbf{X}}' = \mathbf{X}'\mathbf{P}_Z$, 则：

$$\begin{aligned} \hat{\beta}_{GMM} &= (\mathbf{X}'\mathbf{P}_Z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_Z\mathbf{Y} \\ &= (\hat{\mathbf{X}}'\mathbf{X})^{-1}(\hat{\mathbf{X}}'\mathbf{Y}) \end{aligned} \quad (2.69)$$

可见，在随机误差项 u 同方差条件下， GMM 估计量等价于二阶段最小二乘 (2SLS) 估计量，在经济计量软件中可通过工具变量 (IV) 法进行估计。

二 过度识别约束检验 (Hansen 检验或者 J 检验)

如果矩条件的个数多于参数的个数，即 $m > k$ ，则模型是过度识别的，采用 GMM 是渐近有效的。问题是，这些拟采用的矩条件或过度识别约束

是否真的成立？我们可以通过检验总体矩条件 $E[\mathbf{g}(x_i, \theta)] = 0$ 是否为真来判别。过度识别约束检验也称为检验或者 J 检验。

一般地，对向量值函数 $\mathbf{g}(x_i, \theta)$ ，若过度识别约束成立，则其各阶总体矩均应为零，即：

$$E[\mathbf{g}_j(x_i, \theta)] = 0, j = 1, 2, \dots, m \quad (2.70)$$

原假设为：

$$H_0 : E[\mathbf{g}(x_i, \theta)] = 0 \quad (2.71)$$

表示矩条件成立或过度识别约束有效。备择假设为：

$$H_1 : E[\mathbf{g}(x_i, \theta)] \neq 0 \quad (2.72)$$

表示矩条件不成立或过度识别约束无效。如果约束有效，由于样本矩依概率收敛于总体矩，则：

$$\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \theta) \xrightarrow{P} E[\mathbf{g}(x_i, \theta)] = 0 \quad (2.73)$$

因为：

$$\sqrt{n} \cdot \frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \theta) \xrightarrow{d} N(\mathbf{0}, \Omega_{(m \times m)}) \quad (2.74)$$

其中协方差矩阵 $\Omega_{(m \times m)}$ 为：

$$\Omega_{(m \times m)} = E \left[\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \theta) \right) \cdot \sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{g}(x_i, \theta) \right)' \right] \quad (2.75)$$

令 $\hat{\theta}$ 表示 GMM 估计量。如果过度识别约束是有效的, 汉森 (Hansen, 1982) 构造了如下的 J 统计量:

$$J = \left[\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n g(x_i, \hat{\theta}) \right) \right]' \left\{ \text{Var} \left[\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n g(x_i, \hat{\theta}) \right) \right] \right\}^{-1} \left[\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n g(x_i, \hat{\theta}) \right) \right] = n \cdot \left[\left(\frac{1}{n} \sum_{i=1}^n g(x_i, \hat{\theta}) \right)' \hat{\Omega}^{-1} \left[\left(\frac{1}{n} \sum_{i=1}^n g(x_i, \hat{\theta}) \right) \right] \right] \quad (2.76)$$

汉森证明, 如果在 GMM 估计量中权矩阵 $\hat{\Omega}^{-1}$ 是渐近有效的, 则:

$$J \xrightarrow{d} \chi^2_{p=m-k} \quad (2.77)$$

自由度为 $m-k$

如果 $J > \chi^2_p$, 则拒绝 H_0 , 说明矩条件不成立或过度识别约束无效;

如果 $J \leq \chi^2_p$, 则不能拒绝 $H_0: E[g(x_i, \theta)] = 0$, 说明矩条件成立或过度识别约束有效。

由于 J 统计量恰好是最优 $\hat{\theta}_{GMM}$ 所对应的最小化损失函数

$\left[\frac{1}{n} \sum_{i=1}^n g_{(1 \times m)}(x_i, \theta) \right]' W_{(m \times m)} \left[\frac{1}{n} \sum_{i=1}^n g_{(m \times 1)}(x_i, \theta) \right]$ 的 n 倍, 因此可以把过度识别约束检验统计量 J 看做是 GMM 估计过程的一个副产品。不管在什么情况下, 只要进行最优 GMM 估计, 就不难同时给出 J 的结果。这样做, 不仅估计出了 $\hat{\theta}_{GMM}$, 而且还确定了用于估计 $\hat{\theta}_{GMM}$ 的那些矩条件或过度识别约束是否真的成立, 一举两得。

对于线性回归模型 $y = X\beta + u$, 参数个数为 k 个, 当解释变量中包含随机变量 $E(Xu) \neq 0$ 时, 找到工具变量 Z 满足 $E(Zu) = 0$ 。当残差 u 满足同方差假定, 且工具变量个数 m 大于 k 时, 存在 m 个矩条件, k 个参数。为了检验 m 个矩条件是否都是有效的, 过度识别约束检验的 J 统计量可以简化为:

$$J = n \cdot R^2 \xrightarrow{d} \chi^2_{p=m-k} \quad (2.78)$$

其中 R^2 是指残差 \hat{e} 对所有工具变量 Z (包含外生变量) 回归的拟合优度, 其中 \hat{e} 定义为:

$$\hat{e}_i = y_i - x_i \hat{\beta}_{2SLS} \quad (2.79)$$

在经济计量软件中, $\hat{\beta}_{2SLS}$ 可通过工具变量 (IV) 法估计出来。

3

广义矩估计方法 (generalized method of moments, 简称为 GMM) 的模型参数直接来自于模型利用的矩条件 (moments conditions) (例子见 Greene, 2003; [83] Hall, 2001; [92] Verbeek, 2000; [84] Conley, 1999; [87] Kelejian & Prucha, 1999; [93] 李子奈、叶阿忠, 2000 [85]; 张晓峒, 2003 [91])。这些条件使用的参数可能是线性的, 但通常是非线性的。为确保识别, 矩条件 (moments conditions) 的数量应该至少与未知参数的数量一样多。

通常地, 我们考虑一个模型, 模型的特点在于如下的 R 个矩条件所构成的集合:

$$E[f(X, \theta)] = 0 \quad (3.18)$$

其中 f 是包含 R 个元素的向量函数, 假设 $R \geq K$, 则有 $(R-K)$ 个剩余的识别约束。 X 是观测变量矩阵, 这些变量可能是内生的或者外生的, θ 是包含所有未知参数的 K 维向量。

为了估计 θ , 我们考虑方程 (3.18) 的对应样本:

$$g_N(\theta) = \frac{1}{N} \sum f(X, \theta) = 0 \quad (3.19)$$

³在 <http://edu.duxiu.com/> 中输入 广义矩估计 广义矩方法 经典矩方法

如果 R 个矩条件的数量等于未知参数 K 的数量, 设方程 (3.19) 中的 R 个元素为零, 并且解 θ , 能够获得唯一一致的估计量。如果矩条件的数量大于参数的数量, 通过设方程 (3.19) 为零, 我们求解出的未知参数不唯一。

相反地, 我们选择 θ 为估计量以使样本的矩向量趋于零, 在某种意义上把 $g_N(\theta)$ 的二次形式最小化, 即:

$$\min \Phi(\theta) = \min g_N'(\theta) A_N g_N(\theta) \quad (3.20)$$

其中, A_N 是正定 (positive definite) 权重矩阵。由此可以解得 GMM 估计量 $\hat{\theta}$ (见 Hansen, 1982;^[94] Conley, 1999;^[97] Kelejian & Prucha, 1999^[93])。虽然我们不能够得到一般情形的 GMM 估计量的分析解, 但是能够证明它是一致 (consistent) 的和渐近正态 (asymptotically normal) 的。最优化权重矩阵是矩样本的方差-协方差矩阵 (variance-covariance matrix) 的逆矩阵, 由此可以得到最有效的 GMM 估计量。一般地, 这个矩阵依赖于未知参数向量 θ , 这存在一个线性模型没有遇到的问题, 解将采用一个迭代的估计过程。

Hansen 的表述:

汉森的估计问题的系统表述如下。令 \mathbf{w}_t 为一个 t 期观察到的 $(h \times 1)$ 变量向量, 令 θ 为未知 $(a \times 1)$ 系数向量, 令 $\mathbf{h}(\theta, \mathbf{w}_t)$ 为 $(r \times 1)$ 向量值函数, $\mathbf{h}: (\mathbb{R}^a \times \mathbb{R}^h) \rightarrow \mathbb{R}^r$ 。因为 \mathbf{w}_t 是一个随机变量, 所以 $\mathbf{h}(\theta, \mathbf{w}_t)$ 也是随机变量。令 θ_0 表示 θ 的真实值, 假定这一真实值由性质

$$E\{\mathbf{h}(\theta_0, \mathbf{w}_t)\} = \mathbf{0} \quad (14.1.9)$$

表示, 则向量方程 (14.1.9) 的 r 行有时被称作正交性条件。令 $\mathcal{W}_T \equiv \mathbf{w}'_T, \mathbf{w}'_{T-1}, \dots, \mathbf{w}'_1$ 为包含容量为 T 的样本中全部观察值的 $(Th \times 1)$ 向量, 令 $(r \times 1)$ 向量值函数 $\mathbf{g}(\theta; \mathcal{W}_T)$ 表示 $\mathbf{h}(\theta, \mathbf{w}_t)$ 的样本均值:

$$\mathbf{g}(\theta; \mathcal{W}_T) \equiv (1/T) \sum_{t=1}^T \mathbf{h}(\theta, \mathbf{w}_t). \quad (14.1.10)$$

注意到 $\mathbf{g}: \mathbb{R}^a \rightarrow \mathbb{R}^r$ 。在 GMM 背后的思想是选取 θ 使样本矩 $\mathbf{g}(\theta; \mathcal{W}_T)$ 尽可能接近于零总体矩; 即 GMM 估计量 $\hat{\theta}_T$ 是使数量

$$Q(\theta; \mathcal{W}_T) = [\mathbf{g}(\theta; \mathcal{W}_T)]' \mathbf{W}_T [\mathbf{g}(\theta; \mathcal{W}_T)] \quad (14.1.11)$$

最小的 θ 值, 其中 $\{\mathbf{W}_T\}_{T=1}^{\infty}$ 是一个 $(r \times r)$ 正定权重矩阵序列, \mathbf{W}_T 可以是 \mathcal{W}_T 的函数。通常, 以第 5.7 节描述的数值方法求此最小化。

如果要估计的参数个数 (a) 与正交性条件个数 (r) 相同, 则一般地, 令

$$\mathbf{g}(\hat{\theta}_T; \mathcal{W}_T) = \mathbf{0}, \quad (14.1.12)$$

可使目标函数 (14.1.11) 最小化。如果 $a = r$, 则 GMM 估计量是满足这 r 个方程的 $\hat{\theta}_T$ 值。若不然, 存在比要估计的参数还多的正交性条件 ($r > a$), 则 (14.1.12) 并不恰好成立。 $\mathbf{g}(\hat{\theta}_T; \mathcal{W}_T)$ 的第 i 个元素接近于零的程度取决于权重矩阵 \mathbf{W}_T 给予第 i 个正交性条件多大的权重。

对于任意的 θ 值, $(r \times 1)$ 向量 $\mathbf{g}(\theta; \mathcal{W}_T)$ 的值都是 $(r \times 1)$ 随机向量 $\mathbf{h}(\theta, \mathbf{w}_t)$ 的 T 个实现的样本平均。如果 \mathbf{w}_t 是严格平稳的, 且 $\mathbf{h}(\cdot)$ 是连续的, 则预

期大数定理成立是合适的：

$$g(\theta; \mathcal{Y}_T) \xrightarrow{P} E\{h(\theta, w_i)\}.$$

表达式 $E\{h(\theta, w_i)\}$ 表示的是取决于 θ 值和 w_i 的概率规律的总体值。假定这一函数是关于 θ 连续的, 且 θ_0 是惟一一个使 θ 满足(14.1.9) 的值, 则, 在相当一般的平稳性、连续性以及矩条件下, 使(14.1.11) 最小化的 $\hat{\theta}_T$ 值提供了 θ_0 的一个一致估计; 细节参见汉森(1982), 加朗和怀特(1988), 以及安德鲁斯和费尔(Fair)(1988)。